



ANÁLISIS COMPARATIVO DE ARQUITECTURAS DE APRENDIZAJE AUTOMÁTICO PARA MONITOREO DE SUPERFICIE TERRESTRE



Phase 1

Localización Geográfica



Parámetro	Geográfico (WGS84)	Proyectado (UTM 18N)
Latitud central	4.962° N	548.465 m N
Longitud central	74.909° W	510.088 m E
Área del ROI		4,86 km ²
Sistema de referencia	EPSG:4326	EPSG:32618

Digitalización de Polígonos de Entrenamiento

Cuadro 4: Clases de cobertura del suelo definidas para el entrenamiento

Código	Clase	Descripción	Polígonos
1	Vegetacion	Bosque, vegetación densa	≥ 5
2	Pastos	Pastizales y cultivos	≥ 5
3	Lahar	Depósito volcánico consolidado	≥ 5
4	Urbano	Zonas construidas	≥ 5
Total			≥ 20

Especificaciones Técnicas del Shapefile

Formato: ESRI Shapefile (.shp) / GeoJSON (.geojson)

Sistema de referencia: EPSG:32618 – WGS 84 / UTM Zone 18N

Campos: id (Integer), clase (String, 80)

Software: QGIS 3.x




Phase 2

Modelos



**Arbol de
Decisión
(Decision Tree
– DT)**

Random state=42 y sin
restricción de profundidad
máximo




**Máquina de
Vectores de
Soporte (SVM)**

C=10 y gamma='scale'



**Red Neuronal
Artificial (ANN)**

Arquitectura de dos capas ocultas
de 64 y 32 neurona, máximo de
500 épocas de entrenamiento.



**K-Vecinos más
Cercanos
(KNN)**

k=5 vecinos, utilizando distancia
euclídea



**Naïve Bayes
Gaussiano (NB)**

No requiere escalado.

Métricas Evaluación

Overall Accuracy (OA)

Proporción total de píxeles correctamente clasificados

Coeficiente Kappa de Cohen

mide el acuerdo entre predicciones y etiquetas reales más allá del azar.

Precision, Recall y F1-Score

Evalúan el balance entre exactitud y exhaustividad por clase

Matriz de Confusión

Visualización de errores de clasificación entre pares de clases

Resultados de Entrenamiento

Cuadro 6: Comparación de métricas de desempeño — Phase 2

Modelo	OA	Kappa	Precision	Recall	F1-Score
Decision Tree	0.9144	0.8760	0.9146	0.9144	0.9145
SVM	0.9480	0.9248	0.9494	0.9480	0.9481
ANN	0.9555	0.9358	0.9565	0.9555	0.9557
KNN	0.9410	0.9143	0.9415	0.9410	0.9409
Naive Bayes	0.8280	0.7523	0.8365	0.8280	0.8225

Matrices de Confusión

Análisis de Resultados




Figura 3: Red Neuronal Artificial (ANN)
— mejor modelo

- **Overall Accuracy de 95.55 % y**
- **Coeficiente Kappa de 0.9358**

La arquitectura de dos capas ocultas (64-32 neuronas) logró capturar las relaciones no lineales entre las bandas espectrales con mayor eficacia que los demás modelos.

Matrices de Confusión

Análisis de Resultados

- OA de 94.80 %




Figura 2: Máquina de Vectores de Soporte (SVM)

Matrices de Confusión

Análisis de Resultados

- OA de 94.10 %




Figura 4: K-Vecinos más Cercanos (KNN)

Matrices de Confusión

Análisis de Resultados

- OA de 91.44 %
- Kappa de 0.8760

Permite identificar que umbrales espectrales (en qué bandas) discriminan mejor cada clase de cobertura




Figura 1: Árbol de Decisión (DT)

Matrices de Confusión

Análisis de Resultados

- OA de 82.80 %
- Kappa de 0.7523




Figura 5: Naïve Bayes Gaussiano (NB)

Conclusiones

- ANN ganó (95,55%) porque captura relaciones no lineales entre las 10 bandas
- SVM y KNN quedaron segundo y tercero (~94%) , funcionan bien porque el espacio espectral de Armero está bien separado
- Decision Tree llegó a 91,44% , es aceptable pero se queda corto en clases similares espectralmente (Pastos vs Vegetación)
- Naive Bayes fue el peor (82,80%)