

Proyecto Final: Análisis Comparativo de
Arquitecturas de
Aprendizaje Automático para Monitoreo de
Superficie Terrestre

Phase 1: Definición del Problema

Región de Interés: Armero, Tolima, Colombia

Andrés Oswaldo Calderón Romero, Ph.D. (Docente)

Gabriel Riaño, Maria Angelica Piedrahita, Juan Vargas e Isabella Palacio

Mayo 2026

Índice

1. Introducción y Justificación del Evento	3
1.1. Contexto del Evento	3
1.2. Relevancia para GeoAI	3
2. Delimitación del Área de Estudio	3
2.1. Localización Geográfica	3
2.2. Descripción del Área	4
3. Datos de Teledetección	4
3.1. Metadatos de la Imagen Sentinel-2	4
3.2. Bandas Espectrales Disponibles	5
3.3. Justificación de la Selección de la Imagen	5
4. Construcción del Dataset de Entrenamiento	5
4.1. Digitalización de Polígonos de Entrenamiento	5
4.2. Especificaciones Técnicas del Shapefile	6
4.3. Extracción del Dataset Tabular (TSV)	6
5. Metodología y Herramientas	7
5.1. Software Utilizado	7
5.2. Flujo de Trabajo	7
	1

6. Estructura de Archivos del Proyecto	8
7. Conclusión de la Phase 1	9

1. Introducción y Justificación del Evento

El presente proyecto selecciona como Región de Interés (ROI) la zona de **Armero Viejo**, municipio de Armero-Guayabal, departamento del Tolima, Colombia. Esta área constituye uno de los casos más representativos de desastre natural en América Latina y ofrece condiciones espectrales únicas para la clasificación supervisada de coberturas del suelo mediante imágenes satelitales Sentinel-2.

1.1. Contexto del Evento

El **13 de noviembre de 1985**, la erupción del volcán **Nevado del Ruiz** (4.900 m.s.n.m.) desencadenó una serie de lahares (flujos de lodo volcánico) que descendieron por los ríos Lagunilla, Chinchiná y Gualí. El lahar principal sepultó casi en su totalidad la ciudad de Armero en cuestión de minutos, causando entre 20.000 y 25.000 víctimas fatales sobre una población de aproximadamente 29.000 habitantes.

1.2. Relevancia para GeoAI

Desde la perspectiva de la Inteligencia Artificial Geoespacial (GeoAI), Armero representa un caso de estudio ideal por las siguientes razones:

- **Diversidad espectral:** La zona presenta coberturas claramente diferenciables para el entrenamiento supervisado: lahar consolidado, vegetación densa, pastos/cultivos y área urbana. Aunque el área de estudio incluye el cauce del río Lagunilla, para esta fase inicial se decidió no incorporar la clase agua debido a la dificultad de delimitar muestras limpias y suficientemente representativas en la imagen utilizada.
- **Contraste espectral:** El depósito de lahar consolidado exhibe una firma espectral marcadamente diferente a la vegetación circundante, facilitando la separabilidad entre clases.
- **Relevancia ambiental:** El monitoreo de la recuperación ecológica post-desastre constituye una aplicación directa del pipeline de teledetección.
- **Disponibilidad de datos:** La zona cuenta con cobertura óptima del satélite Sentinel-2 con baja nubosidad durante la temporada seca.

2. Delimitación del Área de Estudio

2.1. Localización Geográfica

La Región de Interés se localiza en las coordenadas centrales aproximadas de:

Cuadro 1: Coordenadas aproximadas del área de estudio

Parámetro	Geográfico (WGS84)	Proyectado (UTM 18N)
Latitud central	4.962° N	548.465 m N
Longitud central	74.909° W	510.088 m E
Área del ROI		4,86 km ²
Sistema de referencia	EPSG:4326	EPSG:32618

2.2. Descripción del Área

El ROI abarca la totalidad del depósito de lahar de Armero Viejo y su entorno inmediato, incluyendo:

- La zona central del depósito de lahar consolidado (área gris-café característica)
- Vegetación secundaria y bosque ripario en los márgenes del río Lagunilla
- Pastos y cultivos en las zonas de transición
- Sector urbano del municipio de Armero-Guayabal al norte del ROI
- Cauce del río Lagunilla en el extremo sur del área

3. Datos de Teledetección

3.1. Metadatos de la Imagen Sentinel-2

La imagen satelital utilizada para este proyecto fue adquirida del archivo *Copernicus Data Space Ecosystem* (European Space Agency). Los metadatos completos se presentan a continuación:

Cuadro 2: Metadatos de la imagen Sentinel-2 seleccionada

Campo	Valor
Nombre del producto	S2B_MSIL2A_20240123T152649_N0510_R025_T18NWL
Misión	Sentinel-2B (ESA/Copernicus)
Instrumento	MSI (Multispectral Instrument)
Nivel de procesamiento	L2A (Reflectancia de superficie, corrección atmosférica)
Fecha de adquisición	23 de enero de 2024
Hora de adquisición (UTC)	15:26:49
Tile	T18NWL
Órbita relativa	R025
Tamaño del archivo	1.161 MB
Porcentaje de nubes (escena)	~30 % (0 % sobre el ROI)

3.2. Bandas Espectrales Disponibles

Cuadro 3: Bandas espectrales Sentinel-2 utilizadas en el proyecto

Banda	Nombre	Longitud de onda (nm)	Resolución	Uso
B02	Azul	490	10 m	Color real, agua
B03	Verde	560	10 m	Color real, vegetación
B04	Rojo	665	10 m	Color real, suelo
B05	Red Edge 1	705	20 m	Estado vegetal
B06	Red Edge 2	740	20 m	Estado vegetal
B07	Red Edge 3	783	20 m	Estado vegetal
B08	NIR	842	10 m	Vegetación, NDVI
B8A	NIR estrecho	865	20 m	Vegetación
B11	SWIR 1	1610	20 m	Humedad, geología
B12	SWIR 2	2190	20 m	Minerales, lahar

3.3. Justificación de la Selección de la Imagen

La imagen del 23 de enero de 2024 fue seleccionada por las siguientes razones:

1. **Temporada seca:** Enero corresponde a la temporada seca del departamento del Tolima, garantizando mínima cobertura nubosa sobre el ROI.
2. **Cero nubes sobre Armero:** Verificación visual confirmó ausencia total de nubes sobre el área de estudio.
3. **Nivel L2A:** El producto ya cuenta con corrección atmosférica aplicada (algoritmo Sen2Cor), entregando valores de reflectancia de superficie listos para análisis cuantitativo.
4. **Resolución adecuada:** La resolución de 10 m permite distinguir coberturas de interés como el lahar, la vegetación y los cuerpos de agua.

4. Construcción del Dataset de Entrenamiento

4.1. Digitalización de Polígonos de Entrenamiento

Los polígonos de entrenamiento fueron digitalizados manualmente en **QGIS** sobre la imagen Sentinel-2 en composición de color real (B04-B03-B02). Se definieron cuatro clases de cobertura del suelo representativas del área de estudio:

Cuadro 4: Clases de cobertura del suelo definidas para el entrenamiento

Código	Clase	Descripción	Polígonos
1	Vegetacion	Bosque, vegetación densa	≥ 5
2	Pastos	Pastizales y cultivos	≥ 5
3	Lahar	Depósito volcánico consolidado	≥ 5
4	Urbano	Zonas construidas	≥ 5
Total			≥ 20



Figura 1: Polígonos de entrenamiento digitalizados sobre imagen Sentinel-2 en composición color real (B04-B03-B02)

4.2. Especificaciones Técnicas del Shapefile

- **Formato:** ESRI Shapefile (.shp) / GeoJSON (.geojson)
- **Sistema de referencia:** EPSG:32618 — WGS 84 / UTM Zone 18N
- **Campos:** id (Integer), clase (String, 80)
- **Software:** QGIS 3.x

4.3. Extracción del Dataset Tabular (TSV)

La extracción del dataset tabular se realizó mediante un script en Python denominado `extraccion_tsv.py`. El procedimiento tomó como entrada las bandas Sentinel-2 en formato .jp2 y el archivo vectorial `poligonos_entrenamiento.geojson`, previamente generado en QGIS. Cada polígono fue utilizado como muestra de referencia para extraer los valores espectrales de los píxeles contenidos en su interior.

Para la construcción del dataset se emplearon diez bandas espectrales: B02, B03, B04, B05, B06, B07, B08, B8A, B11 y B12. Las bandas de 20 metros fueron alineadas con las bandas de 10 metros mediante remuestreo, tomando como referencia espacial la banda

B02. Posteriormente, los valores digitales fueron escalados dividiéndolos por 10.000, con el fin de obtener valores aproximados de reflectancia de superficie.

El archivo resultante fue exportado en formato Tab-Separated Values (TSV) bajo el nombre `dataset_armero.tsv`. La tabla contiene las columnas `latitude`, `longitude`, las diez bandas espectrales seleccionadas y la etiqueta categórica `clase`. En total, se obtuvieron 25.748 píxeles de entrenamiento distribuidos en cuatro clases.

Cuadro 5: Distribución de píxeles extraídos por clase

Clase	Número de píxeles
Pastos	11.223
Lahar	6.476
Vegetacion	5.606
Urbano	2.443
Total	25.748

La distribución evidencia un desbalance entre clases, especialmente por la mayor cantidad de píxeles asociados a Pastos frente a Urbano. Por esta razón, para la fase de entrenamiento se recomienda aplicar una estrategia de muestreo estratificado o balanceo de clases, con el fin de reducir posibles sesgos durante el ajuste de los modelos de clasificación.

5. Metodología y Herramientas

5.1. Software Utilizado

- **QGIS 3.x:** Visualización, recorte del ROI y digitalización de polígonos
- **Python 3.x:** Extracción de píxeles y construcción del dataset
 - **rasterio:** Lectura de imágenes raster (.jp2, .tif)
 - **geopandas:** Manejo de capas vectoriales (.shp, .geojson)
 - **numpy:** Operaciones matriciales sobre bandas espectrales
 - **pandas:** Construcción y exportación del dataset tabular
- **Copernicus Data Space:** Descarga de imágenes Sentinel-2 L2A

5.2. Flujo de Trabajo

El flujo de trabajo de la Phase 1 sigue la siguiente secuencia:

1. Selección del ROI correspondiente a Armero Viejo, Tolima.

2. Descarga y organización de bandas Sentinel-2 L2A en formato `.jp2`.
3. Carga y visualización de la imagen en QGIS mediante la composición color real TCI_10m.
4. Creación de una capa vectorial tipo polígono en formato Shapefile.
5. Digitalización manual de polígonos de entrenamiento para las clases Vegetacion, Pastos, Lahar y Urbano.
6. Exportación del shapefile como GeoJSON (`poligonos_entrenamiento.geojson`).
7. Extracción de valores espectrales con Python mediante el script `extraccion_tsv.py`.
8. Exportación del dataset final en formato TSV (`dataset_armero.tsv`).

6. Estructura de Archivos del Proyecto

```
proyecto_armero/  
  imagen/  
    T18NWL_20240123T152649_B02_10m.jp2  
    T18NWL_20240123T152649_B03_10m.jp2  
    T18NWL_20240123T152649_B04_10m.jp2  
    T18NWL_20240123T152649_B05_20m.jp2  
    T18NWL_20240123T152649_B06_20m.jp2  
    T18NWL_20240123T152649_B07_20m.jp2  
    T18NWL_20240123T152649_B08_10m.jp2  
    T18NWL_20240123T152649_B8A_20m.jp2  
    T18NWL_20240123T152649_B11_20m.jp2  
    T18NWL_20240123T152649_B12_20m.jp2  
    T18NWL_20240123T152649_TCI_10m.jp2  
  vectorial/  
    armero_centro.csv  
    poligonos_entrenamiento.shp  
    poligonos_entrenamiento.shx  
    poligonos_entrenamiento.dbf  
    poligonos_entrenamiento.prj  
    poligonos_entrenamiento.geojson  
  scripts/  
    extraccion_tsv.py  
  dataset/  
    dataset_armero.tsv
```


7. Conclusión de la Phase 1

El dataset resultante, construido a partir de 19 polígonos de entrenamiento distribuidos en cuatro clases espectralmente diferenciables, proporcionó una base inicial adecuada para la siguiente fase del proyecto. A partir de estos polígonos se extrajeron 25.748 píxeles de entrenamiento con información espectral de diez bandas Sentinel-2 y su respectiva etiqueta de clase.

Estos datos permitirán entrenar y comparar los cinco modelos de machine learning definidos en el proyecto: Árbol de Decisión (DT), Máquina de Vectores de Soporte (SVM), Red Neuronal Artificial (ANN), K-Vecinos más Cercanos (KNN) y Naïve Bayes (NB). Dado el desbalance observado entre clases, especialmente entre Pastos y Urbano, la siguiente fase deberá incorporar estrategias de partición estratificada o balanceo de muestras antes del entrenamiento de los modelos.