

Proyecto Final: Análisis Comparativo de
Arquitecturas de
Aprendizaje Automático para Monitoreo de
Superficie Terrestre

Phases 1 & 2: Definición del Problema y Entrenamiento de
Modelos

Región de Interés: Armero, Tolima, Colombia

Andrés Oswaldo Calderón Romero, Ph.D. (Docente)

Gabriel Riaño, Maria Angelica Piedrahita, Juan Vargas e Isabella Palacio

Mayo 2026

Índice

1. Introducción y Justificación del Evento	3
1.1. Contexto del Evento	3
1.2. Relevancia para GeoAI	3
2. Delimitación del Área de Estudio	3
2.1. Localización Geográfica	3
2.2. Descripción del Área	4
3. Datos de Teledetección	4
3.1. Metadatos de la Imagen Sentinel-2	4
3.2. Bandas Espectrales Disponibles	5
3.3. Justificación de la Selección de la Imagen	5
4. Construcción del Dataset de Entrenamiento	5
4.1. Digitalización de Polígonos de Entrenamiento	5
4.2. Especificaciones Técnicas del Shapefile	6
4.3. Extracción del Dataset Tabular (TSV)	6

5. Metodología y Herramientas	7
5.1. Software Utilizado	7
5.2. Flujo de Trabajo	7
6. Conclusión de la Phase 1	8
7. Phase 2: Preprocesamiento y Entrenamiento de Modelos	8
7.1. Introducción	8
7.2. División del Dataset	8
7.3. Modelos Implementados y Configuración	9
7.3.1. Árbol de Decisión (Decision Tree — DT)	9
7.3.2. Máquina de Vectores de Soporte (SVM)	9
7.3.3. Red Neuronal Artificial (ANN)	9
7.3.4. K-Vecinos más Cercanos (KNN)	9
7.3.5. Naïve Bayes Gaussiano (NB)	9
7.4. Métricas de Evaluación	9
7.5. Resultados de Entrenamiento	10
7.6. Matrices de Confusión	10
7.7. Análisis de Resultados	11
7.7.1. Modelo de Mejor Desempeño: ANN	11
7.7.2. Rendimiento de los Modelos Kernel y de Vecindad	11
7.7.3. Árbol de Decisión	12
7.7.4. Naïve Bayes: Modelo de Menor Desempeño	12
7.8. Conclusión de la Phase 2	12

1. Introducción y Justificación del Evento

El presente proyecto selecciona como Región de Interés (ROI) la zona de **Armero Viejo**, municipio de Armero-Guayabal, departamento del Tolima, Colombia. Esta área constituye uno de los casos más representativos de desastre natural en América Latina y ofrece condiciones espectrales únicas para la clasificación supervisada de coberturas del suelo mediante imágenes satelitales Sentinel-2.

1.1. Contexto del Evento

El **13 de noviembre de 1985**, la erupción del volcán **Nevado del Ruiz** (4.900 m.s.n.m.) desencadenó una serie de lahares (flujos de lodo volcánico) que descendieron por los ríos Lagunilla, Chinchiná y Gualí. El lahar principal sepultó casi en su totalidad la ciudad de Armero en cuestión de minutos, causando entre 20.000 y 25.000 víctimas fatales sobre una población de aproximadamente 29.000 habitantes.

1.2. Relevancia para GeoAI

Desde la perspectiva de la Inteligencia Artificial Geoespacial (GeoAI), Armero representa un caso de estudio ideal por las siguientes razones:

- **Diversidad espectral:** La zona presenta coberturas claramente diferenciables para el entrenamiento supervisado: lahar consolidado, vegetación densa, pastos/cultivos y área urbana. Aunque el área de estudio incluye el cauce del río Lagunilla, para esta fase inicial se decidió no incorporar la clase agua debido a la dificultad de delimitar muestras limpias y suficientemente representativas en la imagen utilizada.
- **Contraste espectral:** El depósito de lahar consolidado exhibe una firma espectral marcadamente diferente a la vegetación circundante, facilitando la separabilidad entre clases.
- **Relevancia ambiental:** El monitoreo de la recuperación ecológica post-desastre constituye una aplicación directa del pipeline de teledetección.
- **Disponibilidad de datos:** La zona cuenta con cobertura óptima del satélite Sentinel-2 con baja nubosidad durante la temporada seca.

2. Delimitación del Área de Estudio

2.1. Localización Geográfica

La Región de Interés se localiza en las coordenadas centrales aproximadas de:

Cuadro 1: Coordenadas aproximadas del área de estudio

Parámetro	Geográfico (WGS84)	Proyectado (UTM 18N)
Latitud central	4.962° N	548.465 m N
Longitud central	74.909° W	510.088 m E
Área del ROI		4,86 km ²
Sistema de referencia	EPSG:4326	EPSG:32618

2.2. Descripción del Área

El ROI abarca la totalidad del depósito de lahar de Armero Viejo y su entorno inmediato, incluyendo:

- La zona central del depósito de lahar consolidado (área gris-café característica)
- Vegetación secundaria y bosque ripario en los márgenes del río Lagunilla
- Pastos y cultivos en las zonas de transición
- Sector urbano del municipio de Armero-Guayabal al norte del ROI
- Cauce del río Lagunilla en el extremo sur del área

3. Datos de Teledetección

3.1. Metadatos de la Imagen Sentinel-2

La imagen satelital utilizada para este proyecto fue adquirida del archivo *Copernicus Data Space Ecosystem* (European Space Agency). Los metadatos completos se presentan a continuación:

Cuadro 2: Metadatos de la imagen Sentinel-2 seleccionada

Campo	Valor
Nombre del producto	S2B_MSIL2A_20240123T152649_N0510_R025_T18NWL
Misión	Sentinel-2B (ESA/Copernicus)
Instrumento	MSI (Multispectral Instrument)
Nivel de procesamiento	L2A (Reflectancia de superficie, corrección atmosférica)
Fecha de adquisición	23 de enero de 2024
Hora de adquisición (UTC)	15:26:49
Tile	T18NWL
Órbita relativa	R025
Tamaño del archivo	1.161 MB
Porcentaje de nubes (escena)	~30 % (0 % sobre el ROI)

3.2. Bandas Espectrales Disponibles

Cuadro 3: Bandas espectrales Sentinel-2 utilizadas en el proyecto

Banda	Nombre	Longitud de onda (nm)	Resolución	Uso
B02	Azul	490	10 m	Color real, agua
B03	Verde	560	10 m	Color real, vegetación
B04	Rojo	665	10 m	Color real, suelo
B05	Red Edge 1	705	20 m	Estado vegetal
B06	Red Edge 2	740	20 m	Estado vegetal
B07	Red Edge 3	783	20 m	Estado vegetal
B08	NIR	842	10 m	Vegetación, NDVI
B8A	NIR estrecho	865	20 m	Vegetación
B11	SWIR 1	1610	20 m	Humedad, geología
B12	SWIR 2	2190	20 m	Minerales, lahar

3.3. Justificación de la Selección de la Imagen

La imagen del 23 de enero de 2024 fue seleccionada por las siguientes razones:

1. **Temporada seca:** Enero corresponde a la temporada seca del departamento del Tolima, garantizando mínima cobertura nubosa sobre el ROI.
2. **Cero nubes sobre Armero:** Verificación visual confirmó ausencia total de nubes sobre el área de estudio.
3. **Nivel L2A:** El producto ya cuenta con corrección atmosférica aplicada (algoritmo Sen2Cor), entregando valores de reflectancia de superficie listos para análisis cuantitativo.
4. **Resolución adecuada:** La resolución de 10 m permite distinguir coberturas de interés como el lahar, la vegetación y los cuerpos de agua.

4. Construcción del Dataset de Entrenamiento

4.1. Digitalización de Polígonos de Entrenamiento

Los polígonos de entrenamiento fueron digitalizados manualmente en **QGIS** sobre la imagen Sentinel-2 en composición de color real (B04-B03-B02). Se definieron cuatro clases de cobertura del suelo representativas del área de estudio:

Cuadro 4: Clases de cobertura del suelo definidas para el entrenamiento

Código	Clase	Descripción	Polígonos
1	Vegetacion	Bosque, vegetación densa	≥ 5
2	Pastos	Pastizales y cultivos	≥ 5
3	Lahar	Depósito volcánico consolidado	≥ 5
4	Urbano	Zonas construidas	≥ 5
Total			≥ 20

4.2. Especificaciones Técnicas del Shapefile

- **Formato:** ESRI Shapefile (.shp) / GeoJSON (.geojson)
- **Sistema de referencia:** EPSG:32618 — WGS 84 / UTM Zone 18N
- **Campos:** `id` (Integer), `clase` (String, 80)
- **Software:** QGIS 3.x

4.3. Extracción del Dataset Tabular (TSV)

La extracción del dataset tabular se realizó mediante un script en Python denominado `extraccion_tsv.py`. El procedimiento tomó como entrada las bandas Sentinel-2 en formato `.jp2` y el archivo vectorial `poligonos_entrenamiento.geojson`, previamente generado en QGIS. Cada polígono fue utilizado como muestra de referencia para extraer los valores espectrales de los píxeles contenidos en su interior.

Para la construcción del dataset se emplearon diez bandas espectrales: B02, B03, B04, B05, B06, B07, B08, B8A, B11 y B12. Las bandas de 20 metros fueron alineadas con las bandas de 10 metros mediante remuestreo, tomando como referencia espacial la banda B02. Posteriormente, los valores digitales fueron escalados dividiéndolos por 10.000, con el fin de obtener valores aproximados de reflectancia de superficie.

El archivo resultante fue exportado en formato Tab-Separated Values (TSV) bajo el nombre `dataset_armero.tsv`. La tabla contiene las columnas `latitude`, `longitude`, las diez bandas espectrales seleccionadas y la etiqueta categórica `clase`. En total, se obtuvieron 25.748 píxeles de entrenamiento distribuidos en cuatro clases.

La distribución evidencia un desbalance entre clases, especialmente por la mayor cantidad de píxeles asociados a Pastos frente a Urbano. Por esta razón, para la fase de entrenamiento se recomienda aplicar una estrategia de muestreo estratificado o balanceo de clases, con el fin de reducir posibles sesgos durante el ajuste de los modelos de clasificación.

Cuadro 5: Distribución de píxeles extraídos por clase

Clase	Número de píxeles
Pastos	11.223
Lahar	6.476
Vegetacion	5.606
Urbano	2.443
Total	25.748

5. Metodología y Herramientas

5.1. Software Utilizado

- **QGIS 3.x:** Visualización, recorte del ROI y digitalización de polígonos
- **Python 3.x:** Extracción de píxeles y construcción del dataset
 - **rasterio:** Lectura de imágenes raster (.jp2, .tif)
 - **geopandas:** Manejo de capas vectoriales (.shp, .geojson)
 - **numpy:** Operaciones matriciales sobre bandas espectrales
 - **pandas:** Construcción y exportación del dataset tabular
- **Copernicus Data Space:** Descarga de imágenes Sentinel-2 L2A

5.2. Flujo de Trabajo

El flujo de trabajo de la Phase 1 sigue la siguiente secuencia:

1. Selección del ROI correspondiente a Armero Viejo, Tolima.
2. Descarga y organización de bandas Sentinel-2 L2A en formato .jp2.
3. Carga y visualización de la imagen en QGIS mediante la composición color real TCI_10m.
4. Creación de una capa vectorial tipo polígono en formato Shapefile.
5. Digitalización manual de polígonos de entrenamiento para las clases Vegetacion, Pastos, Lahar y Urbano.
6. Exportación del shapefile como GeoJSON (`poligonos_entrenamiento.geojson`).
7. Extracción de valores espectrales con Python mediante el script `extraccion_tsv.py`.
8. Exportación del dataset final en formato TSV (`dataset_armero.tsv`).

6. Conclusión de la Phase 1

El dataset resultante, construido a partir de 19 polígonos de entrenamiento distribuidos en cuatro clases espectralmente diferenciables, proporcionó una base inicial adecuada para la siguiente fase del proyecto. A partir de estos polígonos se extrajeron 25.748 píxeles de entrenamiento con información espectral de diez bandas Sentinel-2 y su respectiva etiqueta de clase.

Estos datos permitirán entrenar y comparar los cinco modelos de machine learning definidos en el proyecto: Árbol de Decisión (DT), Máquina de Vectores de Soporte (SVM), Red Neuronal Artificial (ANN), K-Vecinos más Cercanos (KNN) y Naïve Bayes (NB). Dado el desbalance observado entre clases, especialmente entre Pastos y Urbano, la siguiente fase deberá incorporar estrategias de partición estratificada o balanceo de muestras antes del entrenamiento de los modelos.

7. Phase 2: Preprocesamiento y Entrenamiento de Modelos

7.1. Introducción

En esta segunda fase se implementaron, entrenaron y evaluaron cinco arquitecturas de aprendizaje automático sobre el dataset tabular construido en la Phase 1. El objetivo fue comparar el desempeño de cada modelo en la clasificación de coberturas del suelo de Armero Viejo, utilizando como entrada los valores espectrales de las diez bandas Sentinel-2. El script principal de esta fase es `phase2_training.py`, disponible en el directorio `scripts/` del repositorio del proyecto.

7.2. División del Dataset

El dataset de 25.748 píxeles fue dividido en conjuntos de entrenamiento y prueba mediante la función `train_test_split` de `scikit-learn`, con los siguientes parámetros:

- **Proporción:** 70 % entrenamiento / 30 % prueba.
- **Estratificación:** `stratify=y`, garantizando que la distribución de clases se preserve en ambos subconjuntos, lo que mitiga el efecto del desbalance entre Pastos y Urbano.
- **Semilla aleatoria:** `random_state=42`, asegurando reproducibilidad.

Esto resultó en aproximadamente 18.023 píxeles para entrenamiento y 7.724 para prueba.

7.3. Modelos Implementados y Configuración

Se implementaron cinco modelos de clasificación supervisada. Los modelos que requieren datos en escala comparable fueron envueltos en un `Pipeline` que incluye un paso de `StandardScaler` previo al clasificador.

7.3.1. Árbol de Decisión (Decision Tree — DT)

Modelo basado en particiones jerárquicas del espacio de características espectrales. Se configuró con `random_state=42` y sin restricción de profundidad máxima, permitiendo al árbol crecer hasta la pureza total de los nodos hoja.

7.3.2. Máquina de Vectores de Soporte (SVM)

Algoritmo de margen máximo con kernel RBF (*Radial Basis Function*), configurado con `C=10` y `gamma='scale'`. Al operar en un espacio de alta dimensionalidad, el escalado previo de las características es obligatorio.

7.3.3. Red Neuronal Artificial (ANN)

Perceptrón multicapa implementado con `MLPClassifier`, con arquitectura de dos capas ocultas de 64 y 32 neuronas respectivamente, función de activación ReLU por defecto y un máximo de 500 épocas de entrenamiento.

7.3.4. K-Vecinos más Cercanos (KNN)

Clasificador no paramétrico configurado con `k=5` vecinos, utilizando distancia euclídea en el espacio espectral escalado.

7.3.5. Naïve Bayes Gaussiano (NB)

Clasificador probabilístico que asume independencia condicional entre bandas y distribución gaussiana de los valores espectrales por clase. No requiere escalado.

7.4. Métricas de Evaluación

Para cada modelo se calcularon las siguientes métricas sobre el conjunto de prueba:

- **Overall Accuracy (OA):** proporción total de píxeles correctamente clasificados.
- **Coefficiente Kappa de Cohen:** mide el acuerdo entre predicciones y etiquetas reales más allá del azar.
- **Precision, Recall y F1-Score** (ponderados por soporte de clase): evalúan el balance entre exactitud y exhaustividad por clase.

- **Matriz de Confusión:** visualización de errores de clasificación entre pares de clases, exportada como imagen PNG.

7.5. Resultados de Entrenamiento

La Tabla 6 presenta el resumen comparativo de los cinco modelos, obtenido del archivo `phase2_model_results.csv`.

Cuadro 6: Comparación de métricas de desempeño — Phase 2

Modelo	OA	Kappa	Precision	Recall	F1-Score
Decision Tree	0.9144	0.8760	0.9146	0.9144	0.9145
SVM	0.9480	0.9248	0.9494	0.9480	0.9481
ANN	0.9555	0.9358	0.9565	0.9555	0.9557
KNN	0.9410	0.9143	0.9415	0.9410	0.9409
Naive Bayes	0.8280	0.7523	0.8365	0.8280	0.8225

7.6. Matrices de Confusión

Las siguientes figuras muestran las matrices de confusión obtenidas para cada modelo sobre el conjunto de prueba (30 % del dataset). Los ejes corresponden a las clases reales (eje Y) y las clases predichas (eje X): Lahar, Pastos, Urbano y Vegetacion.




Figura 1: Árbol de Decisión (DT)




Figura 2: Máquina de Vectores de Soporte (SVM)




Figura 3: Red Neuronal Artificial (ANN)
— mejor modelo




Figura 4: K-Vecinos más Cercanos (KNN)




Figura 5: Naïve Bayes Gaussiano (NB)

7.7. Análisis de Resultados

7.7.1. Modelo de Mejor Desempeño: ANN

La Red Neuronal Artificial obtuvo el mejor rendimiento en todas las métricas evaluadas, con una **Overall Accuracy de 95.55 %** y un **Coefficiente Kappa de 0.9358**. Estos valores indican un acuerdo casi perfecto entre las predicciones del modelo y las etiquetas de referencia. La arquitectura de dos capas ocultas (64-32 neuronas) logró capturar las relaciones no lineales entre las bandas espectrales con mayor eficacia que los demás modelos.

7.7.2. Rendimiento de los Modelos Kernel y de Vecindad

SVM y KNN obtuvieron desempeños similares (OA de 94.80 % y 94.10 % respectivamente), lo que sugiere que la estructura del espacio espectral es suficientemente compacta

para que tanto el margen máximo como la proximidad métrica sean criterios de clasificación efectivos.

7.7.3. Árbol de Decisión

Con una OA de 91.44 % y Kappa de 0.8760, el Árbol de Decisión ofrece resultados aceptables con la ventaja adicional de la interpretabilidad: permite identificar qué umbrales espectrales (en qué bandas) discriminan mejor cada clase de cobertura.

7.7.4. Naïve Bayes: Modelo de Menor Desempeño

El clasificador Naïve Bayes obtuvo la menor OA (82.80 %) y el Kappa más bajo (0.7523), lo cual era previsible dado que el supuesto de independencia condicional entre bandas espectrales no se cumple en datos de teledetección multibanda, donde las correlaciones inter-banda son inherentes a la física de la reflectancia superficial.

7.8. Conclusión de la Phase 2

Los resultados de esta fase confirman que todos los modelos implementados alcanzan niveles de exactitud superiores al 80 % en la clasificación de coberturas del suelo de Armero Viejo, con el modelo ANN destacándose como el más robusto (OA = 95.55 %, Kappa = 0.9358). El SVM ocupa la segunda posición con métricas comparables, lo que lo convierte en una alternativa viable considerando su mayor velocidad de inferencia.

De cara a la **Phase 3**, la ANN será utilizada como modelo principal para la inferencia sobre el raster completo del ROI. Se procederá a: (1) aplicar el modelo entrenado sobre la pila multibanda completa de Sentinel-2, (2) exportar el raster temático resultante en formato GeoTIFF con conservación del CRS original (EPSG:32618), (3) aplicar simbología discreta en QGIS para visualizar las cuatro clases de cobertura, y (4) cuantificar el área en hectáreas de cada clase predicha.