

Proyecto Final: Análisis Comparativo de  
Arquitecturas de  
Aprendizaje Automático para Monitoreo de  
Superficie Terrestre

Región de Interés: Armero, Tolima, Colombia

Andrés Oswaldo Calderón Romero, Ph.D. (Docente)

*Gabriel Riaño, Maria Angelica Piedrahita, Juan Vargas e Isabella Palacio*

Mayo 2026

Índice

|                                                             |          |
|-------------------------------------------------------------|----------|
| <b>1. Introducción y Justificación del Evento</b>           | <b>3</b> |
| 1.1. Contexto del Evento . . . . .                          | 3        |
| 1.2. Relevancia para GeoAI . . . . .                        | 3        |
| <b>2. Delimitación del Área de Estudio</b>                  | <b>3</b> |
| 2.1. Localización Geográfica . . . . .                      | 3        |
| 2.2. Descripción del Área . . . . .                         | 4        |
| <b>3. Datos de Teledetección</b>                            | <b>4</b> |
| 3.1. Metadatos de la Imagen Sentinel-2 . . . . .            | 4        |
| 3.2. Bandas Espectrales Disponibles . . . . .               | 5        |
| 3.3. Justificación de la Selección de la Imagen . . . . .   | 5        |
| <b>4. Construcción del Dataset de Entrenamiento</b>         | <b>5</b> |
| 4.1. Digitalización de Polígonos de Entrenamiento . . . . . | 5        |
| 4.2. Especificaciones Técnicas del Shapefile . . . . .      | 6        |
| 4.3. Extracción del Dataset Tabular (TSV) . . . . .         | 6        |
| <b>5. Metodología y Herramientas</b>                        | <b>7</b> |
| 5.1. Software Utilizado . . . . .                           | 7        |
| 5.2. Flujo de Trabajo . . . . .                             | 8        |

|                                                                  |           |
|------------------------------------------------------------------|-----------|
| <b>6. Conclusión de la Phase 1</b>                               | <b>8</b>  |
| <b>7. Phase 2: Preprocesamiento y Entrenamiento de Modelos</b>   | <b>9</b>  |
| 7.1. Introducción . . . . .                                      | 9         |
| 7.2. División del Dataset . . . . .                              | 9         |
| 7.3. Modelos Implementados y Configuración . . . . .             | 9         |
| 7.3.1. Árbol de Decisión (Decision Tree — DT) . . . . .          | 9         |
| 7.3.2. Máquina de Vectores de Soporte (SVM) . . . . .            | 10        |
| 7.3.3. Red Neuronal Artificial (ANN) . . . . .                   | 10        |
| 7.3.4. K-Vecinos más Cercanos (KNN) . . . . .                    | 10        |
| 7.3.5. Naïve Bayes Gaussiano (NB) . . . . .                      | 10        |
| 7.4. Métricas de Evaluación . . . . .                            | 10        |
| 7.5. Resultados de Entrenamiento . . . . .                       | 10        |
| 7.6. Matrices de Confusión . . . . .                             | 11        |
| 7.7. Análisis de Resultados . . . . .                            | 12        |
| 7.7.1. Modelo de Mejor Desempeño: ANN . . . . .                  | 12        |
| 7.7.2. Rendimiento de los Modelos Kernel y de Vecindad . . . . . | 12        |
| 7.7.3. Árbol de Decisión . . . . .                               | 12        |
| 7.7.4. Naïve Bayes: Modelo de Menor Desempeño . . . . .          | 12        |
| 7.8. Conclusión de la Phase 2 . . . . .                          | 13        |
| <b>8. Phase 3: Síntesis y Predicción Espacial</b>                | <b>14</b> |
| 8.1. Introducción . . . . .                                      | 14        |
| 8.2. Estrategia de Inferencia . . . . .                          | 14        |
| 8.3. Configuración Técnica del Raster de Salida . . . . .        | 15        |
| 8.4. Mapeo de Clases . . . . .                                   | 15        |
| 8.5. Mapa Temático Clasificado . . . . .                         | 15        |
| 8.6. Cuantificación de Áreas por Clase . . . . .                 | 16        |
| 8.7. Consistencia Espacial y Validación Visual . . . . .         | 17        |
| 8.8. Modelo final, normalización e hiperparámetros . . . . .     | 17        |
| 8.9. Conclusión General del Proyecto . . . . .                   | 18        |

# 1. Introducción y Justificación del Evento

El presente proyecto selecciona como Región de Interés (ROI) la zona de **Armero Viejo**, municipio de Armero-Guayabal, departamento del Tolima, Colombia. Esta área constituye uno de los casos más representativos de desastre natural en América Latina y ofrece condiciones espectrales únicas para la clasificación supervisada de coberturas del suelo mediante imágenes satelitales Sentinel-2.

## 1.1. Contexto del Evento

El **13 de noviembre de 1985**, la erupción del volcán **Nevado del Ruiz** (4.900 m.s.n.m.) desencadenó una serie de lahares (flujos de lodo volcánico) que descendieron por los ríos Lagunilla, Chinchiná y Gualí. El lahar principal sepultó casi en su totalidad la ciudad de Armero en cuestión de minutos, causando entre 20.000 y 25.000 víctimas fatales sobre una población de aproximadamente 29.000 habitantes.

## 1.2. Relevancia para GeoAI

Desde la perspectiva de la Inteligencia Artificial Geoespacial (GeoAI), Armero representa un caso de estudio ideal por las siguientes razones:

- **Diversidad espectral:** La zona presenta coberturas claramente diferenciables para el entrenamiento supervisado: lahar consolidado, vegetación densa, pastos/cultivos y área urbana. Aunque el área de estudio incluye el cauce del río Lagunilla, para esta fase inicial se decidió no incorporar la clase agua debido a la dificultad de delimitar muestras limpias y suficientemente representativas en la imagen utilizada.
- **Contraste espectral:** El depósito de lahar consolidado exhibe una firma espectral marcadamente diferente a la vegetación circundante, facilitando la separabilidad entre clases.
- **Relevancia ambiental:** El monitoreo de la recuperación ecológica post-desastre constituye una aplicación directa del pipeline de teledetección.
- **Disponibilidad de datos:** La zona cuenta con cobertura óptima del satélite Sentinel-2 con baja nubosidad durante la temporada seca.

# 2. Delimitación del Área de Estudio

## 2.1. Localización Geográfica

La Región de Interés se localiza en las coordenadas centrales aproximadas de:

Cuadro 1: Coordenadas aproximadas del área de estudio

| Parámetro             | Geográfico (WGS84) | Proyectado (UTM 18N) |
|-----------------------|--------------------|----------------------|
| Latitud central       | 4.962° N           | 548.465 m N          |
| Longitud central      | 74.909° W          | 510.088 m E          |
| Área del ROI          |                    | 4,86 km <sup>2</sup> |
| Sistema de referencia | EPSG:4326          | EPSG:32618           |

2.2. Descripción del Área

El ROI abarca la totalidad del depósito de lahar de Armero Viejo y su entorno inmediato, incluyendo:

- La zona central del depósito de lahar consolidado (área gris-café característica)
- Vegetación secundaria y bosque ripario en los márgenes del río Lagunilla
- Pastos y cultivos en las zonas de transición
- Sector urbano del municipio de Armero-Guayabal al norte del ROI
- Cauce del río Lagunilla en el extremo sur del área

3. Datos de Teledetección

3.1. Metadatos de la Imagen Sentinel-2

La imagen satelital utilizada para este proyecto fue adquirida del archivo *Copernicus Data Space Ecosystem* (European Space Agency). Los metadatos completos se presentan a continuación:

Cuadro 2: Metadatos de la imagen Sentinel-2 seleccionada

| Campo                        | Valor                                                    |
|------------------------------|----------------------------------------------------------|
| Nombre del producto          | S2B_MSIL2A_20240123T152649_N0510_R025_T18NWL             |
| Misión                       | Sentinel-2B (ESA/Copernicus)                             |
| Instrumento                  | MSI (Multispectral Instrument)                           |
| Nivel de procesamiento       | L2A (Reflectancia de superficie, corrección atmosférica) |
| Fecha de adquisición         | 23 de enero de 2024                                      |
| Hora de adquisición (UTC)    | 15:26:49                                                 |
| Tile                         | T18NWL                                                   |
| Órbita relativa              | R025                                                     |
| Tamaño del archivo           | 1.161 MB                                                 |
| Porcentaje de nubes (escena) | ~30 % (0 % sobre el ROI)                                 |

### 3.2. Bandas Espectrales Disponibles

Cuadro 3: Bandas espectrales Sentinel-2 utilizadas en el proyecto

| Banda | Nombre       | Longitud de onda (nm) | Resolución | Uso                    |
|-------|--------------|-----------------------|------------|------------------------|
| B02   | Azul         | 490                   | 10 m       | Color real, agua       |
| B03   | Verde        | 560                   | 10 m       | Color real, vegetación |
| B04   | Rojo         | 665                   | 10 m       | Color real, suelo      |
| B05   | Red Edge 1   | 705                   | 20 m       | Estado vegetal         |
| B06   | Red Edge 2   | 740                   | 20 m       | Estado vegetal         |
| B07   | Red Edge 3   | 783                   | 20 m       | Estado vegetal         |
| B08   | NIR          | 842                   | 10 m       | Vegetación, NDVI       |
| B8A   | NIR estrecho | 865                   | 20 m       | Vegetación             |
| B11   | SWIR 1       | 1610                  | 20 m       | Humedad, geología      |
| B12   | SWIR 2       | 2190                  | 20 m       | Minerales, lahar       |

### 3.3. Justificación de la Selección de la Imagen

La imagen del 23 de enero de 2024 fue seleccionada por las siguientes razones:

1. **Temporada seca:** Enero corresponde a la temporada seca del departamento del Tolima, garantizando mínima cobertura nubosa sobre el ROI.
2. **Cero nubes sobre Armero:** Verificación visual confirmó ausencia total de nubes sobre el área de estudio.
3. **Nivel L2A:** El producto ya cuenta con corrección atmosférica aplicada (algoritmo Sen2Cor), entregando valores de reflectancia de superficie listos para análisis cuantitativo.
4. **Resolución adecuada:** La resolución de 10 m permite distinguir coberturas de interés como el lahar, la vegetación y los cuerpos de agua.

## 4. Construcción del Dataset de Entrenamiento

### 4.1. Digitalización de Polígonos de Entrenamiento

Los polígonos de entrenamiento fueron digitalizados manualmente en **QGIS** sobre la imagen Sentinel-2 en composición de color real (B04-B03-B02). Se definieron cuatro clases de cobertura del suelo representativas del área de estudio:

Cuadro 4: Clases de cobertura del suelo definidas para el entrenamiento

| Código       | Clase      | Descripción                    | Polígonos |
|--------------|------------|--------------------------------|-----------|
| 1            | Vegetacion | Bosque, vegetación densa       | $\geq 5$  |
| 2            | Pastos     | Pastizales y cultivos          | $\geq 5$  |
| 3            | Lahar      | Depósito volcánico consolidado | $\geq 5$  |
| 4            | Urbano     | Zonas construidas              | $\geq 5$  |
| <b>Total</b> |            |                                | $\geq 20$ |



Figura 1: Polígonos de entrenamiento digitalizados sobre imagen Sentinel-2 en composición color real (B04-B03-B02). Se distinguen las cuatro clases: Vegetacion (verde oscuro), Pastos (verde claro), Lahar (beige) y Urbano (blanco).

## 4.2. Especificaciones Técnicas del Shapefile

- **Formato:** ESRI Shapefile (.shp) / GeoJSON (.geojson)
- **Sistema de referencia:** EPSG:32618 — WGS 84 / UTM Zone 18N
- **Campos:** id (Integer), clase (String, 80)
- **Software:** QGIS 3.x

## 4.3. Extracción del Dataset Tabular (TSV)

La extracción del dataset tabular se realizó mediante un script en Python denominado `extraccion_tsv.py`. El procedimiento tomó como entrada las bandas Sentinel-2 en formato .jp2 y el archivo vectorial `poligonos_entrenamiento.geojson`, previamente

generado en QGIS. Cada polígono fue utilizado como muestra de referencia para extraer los valores espectrales de los píxeles contenidos en su interior.

Para la construcción del dataset se emplearon diez bandas espectrales: B02, B03, B04, B05, B06, B07, B08, B8A, B11 y B12. Las bandas de 20 metros fueron alineadas con las bandas de 10 metros mediante remuestreo, tomando como referencia espacial la banda B02. Posteriormente, los valores digitales fueron escalados dividiéndolos por 10.000, con el fin de obtener valores aproximados de reflectancia de superficie.

El archivo resultante fue exportado en formato Tab-Separated Values (TSV) bajo el nombre `dataset_armero.tsv`. La tabla contiene las columnas `latitude`, `longitude`, las diez bandas espectrales seleccionadas y la etiqueta categórica `clase`. En total, se obtuvieron 25.748 píxeles de entrenamiento distribuidos en cuatro clases.

Cuadro 5: Distribución de píxeles extraídos por clase

| Clase        | Número de píxeles |
|--------------|-------------------|
| Pastos       | 11.223            |
| Lahar        | 6.476             |
| Vegetacion   | 5.606             |
| Urbano       | 2.443             |
| <b>Total</b> | <b>25.748</b>     |

La distribución evidencia un desbalance entre clases, especialmente por la mayor cantidad de píxeles asociados a Pastos frente a Urbano. Por esta razón, para la fase de entrenamiento se recomienda aplicar una estrategia de muestreo estratificado o balanceo de clases, con el fin de reducir posibles sesgos durante el ajuste de los modelos de clasificación.

## 5. Metodología y Herramientas

### 5.1. Software Utilizado

- **QGIS 3.x:** Visualización, recorte del ROI y digitalización de polígonos
- **Python 3.x:** Extracción de píxeles y construcción del dataset
  - **rasterio:** Lectura de imágenes raster (.jp2, .tif)
  - **geopandas:** Manejo de capas vectoriales (.shp, .geojson)
  - **numpy:** Operaciones matriciales sobre bandas espectrales
  - **pandas:** Construcción y exportación del dataset tabular
- **Copernicus Data Space:** Descarga de imágenes Sentinel-2 L2A

## 5.2. Flujo de Trabajo

El flujo de trabajo de la Phase 1 sigue la siguiente secuencia:

1. Selección del ROI correspondiente a Armero Viejo, Tolima.
2. Descarga y organización de bandas Sentinel-2 L2A en formato `.jp2`.
3. Carga y visualización de la imagen en QGIS mediante la composición color real `TCI_10m`.
4. Creación de una capa vectorial tipo polígono en formato Shapefile.
5. Digitalización manual de polígonos de entrenamiento para las clases Vegetacion, Pastos, Lahar y Urbano.
6. Exportación del shapefile como GeoJSON (`poligonos_entrenamiento.geojson`).
7. Extracción de valores espectrales con Python mediante el script `extraccion_tsv.py`.
8. Exportación del dataset final en formato TSV (`dataset_armero.tsv`).

## 6. Conclusión de la Phase 1

El dataset resultante, construido a partir de 19 polígonos de entrenamiento distribuidos en cuatro clases espectralmente diferenciables, proporcionó una base inicial adecuada para la siguiente fase del proyecto. A partir de estos polígonos se extrajeron 25.748 píxeles de entrenamiento con información espectral de diez bandas Sentinel-2 y su respectiva etiqueta de clase.

Estos datos permitirán entrenar y comparar los cinco modelos de machine learning definidos en el proyecto: Árbol de Decisión (DT), Máquina de Vectores de Soporte (SVM), Red Neuronal Artificial (ANN), K-Vecinos más Cercanos (KNN) y Naïve Bayes (NB). Dado el desbalance observado entre clases, especialmente entre Pastos y Urbano, la siguiente fase deberá incorporar estrategias de partición estratificada o balanceo de muestras antes del entrenamiento de los modelos.

## 7. Phase 2: Preprocesamiento y Entrenamiento de Modelos

### 7.1. Introducción

En esta segunda fase se implementaron, entrenaron y evaluaron cinco arquitecturas de aprendizaje automático sobre el dataset tabular construido en la Phase 1. El objetivo fue comparar el desempeño de cada modelo en la clasificación de coberturas del suelo de Armero Viejo, utilizando como entrada los valores espectrales de las diez bandas Sentinel-2. El script principal de esta fase es `phase2_training.py`, disponible en el directorio `scripts/` del repositorio del proyecto.

### 7.2. División del Dataset

El dataset de 25.748 píxeles fue dividido en conjuntos de entrenamiento y prueba mediante la función `train_test_split` de `scikit-learn`, con los siguientes parámetros:

- **Proporción:** 70 % entrenamiento / 30 % prueba.
- **Estratificación:** `stratify=y`, garantizando que la distribución de clases se preserve en ambos subconjuntos, lo que mitiga el efecto del desbalance entre Pastos y Urbano.
- **Semilla aleatoria:** `random_state=42`, asegurando reproducibilidad.

Esto resultó en aproximadamente 18.023 píxeles para entrenamiento y 7.724 para prueba.

### 7.3. Modelos Implementados y Configuración

Se implementaron cinco modelos de clasificación supervisada. Los modelos que requieren datos en escala comparable fueron envueltos en un `Pipeline` que incluye un paso de `StandardScaler` previo al clasificador.

#### 7.3.1. Árbol de Decisión (Decision Tree — DT)

Modelo basado en particiones jerárquicas del espacio de características espectrales. Se configuró con `random_state=42` y sin restricción de profundidad máxima, permitiendo al árbol crecer hasta la pureza total de los nodos hoja.

### 7.3.2. Máquina de Vectores de Soporte (SVM)

Algoritmo de margen máximo con kernel RBF (*Radial Basis Function*), configurado con  $C=10$  y  $\gamma='scale'$ . Al operar en un espacio de alta dimensionalidad, el escalado previo de las características es obligatorio.

### 7.3.3. Red Neuronal Artificial (ANN)

Perceptrón multicapa implementado con `MLPClassifier`, con arquitectura de dos capas ocultas de 64 y 32 neuronas respectivamente, función de activación ReLU por defecto y un máximo de 500 épocas de entrenamiento.

### 7.3.4. K-Vecinos más Cercanos (KNN)

Clasificador no paramétrico configurado con  $k=5$  vecinos, utilizando distancia euclídea en el espacio espectral escalado.

### 7.3.5. Naïve Bayes Gaussiano (NB)

Clasificador probabilístico que asume independencia condicional entre bandas y distribución gaussiana de los valores espectrales por clase. No requiere escalado.

## 7.4. Métricas de Evaluación

Para cada modelo se calcularon las siguientes métricas sobre el conjunto de prueba:

- **Overall Accuracy (OA)**: proporción total de píxeles correctamente clasificados.
- **Coeficiente Kappa de Cohen**: mide el acuerdo entre predicciones y etiquetas reales más allá del azar.
- **Precision, Recall y F1-Score** (ponderados por soporte de clase): evalúan el balance entre exactitud y exhaustividad por clase.
- **Matriz de Confusión**: visualización de errores de clasificación entre pares de clases, exportada como imagen PNG.

## 7.5. Resultados de Entrenamiento

La Tabla 6 presenta el resumen comparativo de los cinco modelos, obtenido del archivo `phase2_model_results.csv`.

Cuadro 6: Comparación de métricas de desempeño — Phase 2

| Modelo        | OA            | Kappa         | Precision     | Recall        | F1-Score      |
|---------------|---------------|---------------|---------------|---------------|---------------|
| Decision Tree | 0.9144        | 0.8760        | 0.9146        | 0.9144        | 0.9145        |
| SVM           | 0.9480        | 0.9248        | 0.9494        | 0.9480        | 0.9481        |
| <b>ANN</b>    | <b>0.9555</b> | <b>0.9358</b> | <b>0.9565</b> | <b>0.9555</b> | <b>0.9557</b> |
| KNN           | 0.9410        | 0.9143        | 0.9415        | 0.9410        | 0.9409        |
| Naive Bayes   | 0.8280        | 0.7523        | 0.8365        | 0.8280        | 0.8225        |

## 7.6. Matrices de Confusión

Las siguientes figuras muestran las matrices de confusión obtenidas para cada modelo sobre el conjunto de prueba (30 % del dataset). Los ejes corresponden a las clases reales (eje Y) y las clases predichas (eje X): Lahar, Pastos, Urbano y Vegetacion.




Figura 2: Árbol de Decisión (DT)




Figura 3: Máquina de Vectores de Soporte (SVM)




Figura 4: Red Neuronal Artificial (ANN) — mejor modelo




Figura 5: K-Vecinos más Cercanos (KNN)




Figura 6: Naïve Bayes Gaussiano (NB)

## 7.7. Análisis de Resultados

### 7.7.1. Modelo de Mejor Desempeño: ANN

La Red Neuronal Artificial obtuvo el mejor rendimiento en todas las métricas evaluadas, con una **Overall Accuracy de 95.55 %** y un **Coefficiente Kappa de 0.9358**. Estos valores indican un acuerdo casi perfecto entre las predicciones del modelo y las etiquetas de referencia. La arquitectura de dos capas ocultas (64-32 neuronas) logró capturar las relaciones no lineales entre las bandas espectrales con mayor eficacia que los demás modelos.

### 7.7.2. Rendimiento de los Modelos Kernel y de Vecindad

SVM y KNN obtuvieron desempeños similares (OA de 94.80 % y 94.10 % respectivamente), lo que sugiere que la estructura del espacio espectral es suficientemente compacta para que tanto el margen máximo como la proximidad métrica sean criterios de clasificación efectivos.

### 7.7.3. Árbol de Decisión

Con una OA de 91.44 % y Kappa de 0.8760, el Árbol de Decisión ofrece resultados aceptables con la ventaja adicional de la interpretabilidad: permite identificar qué umbrales espectrales (en qué bandas) discriminan mejor cada clase de cobertura.

### 7.7.4. Naïve Bayes: Modelo de Menor Desempeño

El clasificador Naïve Bayes obtuvo la menor OA (82.80 %) y el Kappa más bajo (0.7523), lo cual era previsible dado que el supuesto de independencia condicional entre bandas espectrales no se cumple en datos de teledetección multibanda, donde las correlaciones inter-banda son inherentes a la física de la reflectancia superficial.

## 7.8. Conclusión de la Phase 2

Los resultados de esta fase confirman que todos los modelos implementados alcanzan niveles de exactitud superiores al 80 % en la clasificación de coberturas del suelo de Armero Viejo, con el modelo ANN destacándose como el más robusto ( $OA = 95.55\%$ ,  $Kappa = 0.9358$ ). El SVM ocupa la segunda posición con métricas comparables, lo que lo convierte en una alternativa viable considerando su mayor velocidad de inferencia.

De cara a la **Phase 3**, la ANN será utilizada como modelo principal para la inferencia sobre el raster completo del ROI. Se procederá a: (1) aplicar el modelo entrenado sobre la pila multibanda completa de Sentinel-2, (2) exportar el raster temático resultante en formato GeoTIFF con conservación del CRS original (EPSG:32618), (3) aplicar simbología discreta en QGIS para visualizar las cuatro clases de cobertura, y (4) cuantificar el área en hectáreas de cada clase predicha.

## 8. Phase 3: Síntesis y Predicción Espacial

### 8.1. Introducción

La tercera fase constituye la culminación del pipeline GeoAI: el modelo ANN seleccionado en la Phase 2 es reentrenado con la totalidad del dataset y aplicado sobre la pila multibanda completa de Sentinel-2 para producir un mapa temático de coberturas del suelo en formato GeoTIFF georreferenciado. El script responsable de este proceso es `phase3_prediction.py`, ubicado en el directorio `scripts/` del repositorio.

### 8.2. Estrategia de Inferencia

A diferencia de la Phase 2, donde el modelo fue entrenado con el 70 % del dataset y evaluado con el 30 % restante, en la Phase 3 el modelo ANN se entrena con **el 100 % de los 25.748 píxeles** del dataset `dataset_armero.tsv`, maximizando la información disponible para la predicción sobre escena completa.

El flujo del script `phase3_prediction.py` sigue los pasos:

1. Verificación de existencia de todas las bandas Sentinel-2 y del dataset.
2. Carga del dataset y entrenamiento del Pipeline (StandardScaler + ANN) con el 100 % de los datos.
3. Apertura de la banda B02 como referencia espacial (CRS, transformación afín, dimensiones).
4. Alineación de las bandas de 20 m (B05, B06, B07, B8A, B11, B12) a la grilla de 10 m mediante `WarpedVRT` con remuestreo bilineal.
5. Procesamiento por ventanas (*block windows*) para gestionar la memoria eficientemente sobre el raster completo.
6. Escalado de los valores digitales dividiendo por 10.000 para obtener reflectancia de superficie (coherente con el dataset de entrenamiento).
7. Predicción píxel a píxel con el modelo ANN y escritura en el GeoTIFF de salida.
8. Cálculo de áreas por clase a partir del raster clasificado.

### 8.3. Configuración Técnica del Raster de Salida

Cuadro 7: Parámetros del GeoTIFF clasificado generado

| Parámetro             | Valor                                  |
|-----------------------|----------------------------------------|
| Archivo de salida     | <code>classified.armero.ann.tif</code> |
| Formato               | GeoTIFF (GTiff)                        |
| Tipo de dato          | uint8 (entero sin signo, 1 byte)       |
| Compresión            | LZW                                    |
| Número de bandas      | 1 (banda temática)                     |
| Sistema de referencia | EPSG:32618 — WGS 84 / UTM Zone 18N     |
| Resolución espacial   | 10 m × 10 m                            |
| Valor nodata          | 0 (píxeles sin dato / inválidos)       |

### 8.4. Mapeo de Clases

Cada píxel del raster de salida recibe un valor entero correspondiente a su clase predicha, según la siguiente codificación:

Cuadro 8: Codificación de clases en el GeoTIFF final

| Código | Clase      | Color sugerido en QGIS |
|--------|------------|------------------------|
| 1      | Vegetacion | Verde oscuro           |
| 2      | Pastos     | Verde claro / amarillo |
| 3      | Lahar      | Gris / café            |
| 4      | Urbano     | Rojo / magenta         |
| 0      | Sin dato   | Transparente           |

### 8.5. Mapa Temático Clasificado

La Figura 7 presenta el mapa temático de coberturas del suelo generado por el modelo ANN sobre el ROI de Armero Viejo, con simbología discreta aplicada en QGIS.




Figura 7: Mapa de coberturas del suelo — Armero Viejo, Tolima. Clasificación ANN sobre imagen Sentinel-2 (23 enero 2024). Simbología aplicada en QGIS.

## 8.6. Cuantificación de Áreas por Clase

A partir del raster clasificado, el script calculó el área de cada clase multiplicando el conteo de píxeles por el área unitaria de cada píxel ( $10 \text{ m} \times 10 \text{ m} = 100 \text{ m}^2$ ). Los resultados se exportaron al archivo `area_by_class.csv`:

Cuadro 9: Área por clase de cobertura del suelo — Tile T18NWL completo

| Código       | Clase      | Píxeles            | Área (m <sup>2</sup> ) | Área (ha)           | Área (km <sup>2</sup> ) |
|--------------|------------|--------------------|------------------------|---------------------|-------------------------|
| 1            | Vegetacion | 52.736.915         | 5.273.691.500          | 527.369,15          | 5.273,69                |
| 2            | Pastos     | 45.667.021         | 4.566.702.100          | 456.670,21          | 4.566,70                |
| 3            | Lahar      | 13.286.366         | 1.328.636.600          | 132.863,66          | 1.328,64                |
| 4            | Urbano     | 8.870.010          | 887.001.000            | 88.700,10           | 887,00                  |
| <b>Total</b> |            | <b>120.560.312</b> | <b>12.056.031.200</b>  | <b>1.205.603,12</b> | <b>12.056,03</b>        |

**Nota:** Las áreas corresponden a la escena completa del tile T18NWL ( $110 \text{ km} \times 110 \text{ km}$ ), no únicamente al ROI de Armero Viejo delimitado en la Phase 1. La clase Vegetacion domina la escena con el 43,7 % del área total clasificada, seguida de Pastos (37,9 %), Lahar (11,0 %) y Urbano (7,4 %).

## 8.7. Consistencia Espacial y Validación Visual

El raster generado conserva integralmente los parámetros espaciales de la imagen de referencia Sentinel-2 (CRS EPSG:32618, transformación afín y dimensiones de grilla), garantizando la superposición exacta con las capas vectoriales del proyecto. La visualización en QGIS permitió verificar que:

- El depósito de lahar de Armero Viejo es identificado consistentemente como clase Lahar (código 3) en la zona central del ROI.
- La vegetación densa y bosque ripario sobre los márgenes del río Lagunilla es clasificada correctamente como Vegetacion (código 1).
- Las zonas de transición (pastizales y cultivos) corresponden mayoritariamente a Pastos (código 2), coherente con los polígonos de entrenamiento.
- El tejido urbano de Armero-Guayabal al norte del ROI es capturado como Urbano (código 4).

## 8.8. Modelo final, normalización e hiperparámetros

El modelo final seleccionado para la predicción espacial fue la Red Neuronal Artificial (ANN), implementada mediante un MLPClassifier con dos capas ocultas de 64 y 32 neuronas, función de activación ReLU y un máximo de 500 épocas de entrenamiento. Esta elección se justifica porque la ANN obtuvo el mejor desempeño comparativo entre los cinco modelos evaluados en la Phase 2.

En términos cuantitativos, la ANN alcanzó una Overall Accuracy de 95,55

La normalización de los datos mediante StandardScaler fue necesaria porque el modelo ANN trabaja con pesos ajustados durante el entrenamiento y puede verse afectado cuando las variables de entrada se encuentran en escalas diferentes. En este proyecto, las variables corresponden a diez bandas espectrales Sentinel-2, por lo que llevarlas a una escala comparable favorece una convergencia más estable del modelo y evita que alguna banda tenga mayor influencia únicamente por su magnitud numérica.

La arquitectura de dos capas ocultas, con 64 y 32 neuronas, se justifica porque permite capturar relaciones no lineales entre las bandas espectrales y las clases de cobertura del suelo. En imágenes multibanda de teledetección, las clases como Vegetación, Pastos, Lahar y Urbano no siempre se separan mediante reglas lineales simples. Por esta razón, una ANN resulta adecuada, ya que puede aprender combinaciones complejas entre las bandas visibles, red edge, NIR y SWIR.

El uso de 500 épocas como máximo de entrenamiento se justifica como una configuración suficiente para permitir que la red ajuste sus pesos y encuentre patrones espectrales relevantes sin limitar prematuramente el proceso de aprendizaje. Además, el desempeño

obtenido en el conjunto de prueba demuestra que esta configuración fue efectiva, ya que la ANN no solo obtuvo la mayor exactitud global, sino también el mejor equilibrio entre precisión, recall y F1-Score.

Finalmente, la ANN fue seleccionada como modelo final para la Phase 3 porque demostró ser el modelo más robusto en la comparación experimental. Su superioridad frente a los demás modelos indica que logró representar mejor la complejidad espectral del área de estudio, especialmente en un contexto con clases diferenciadas como lahar consolidado, vegetación, pastos/cultivos y zonas urbanas.

## 8.9. Conclusión General del Proyecto

Este proyecto integró de forma exitosa las tres fases del pipeline GeoAI: desde la adquisición y preparación de datos Sentinel-2 (Phase 1), pasando por el entrenamiento y comparación sistemática de cinco arquitecturas de machine learning (Phase 2), hasta la generación de un mapa temático de coberturas del suelo a escala de escena completa (Phase 3).

El modelo ANN (MLP 64-32, StandardScaler) demostró ser el más robusto con una Overall Accuracy de 95.55 % y Kappa de 0.9358, y su aplicación sobre el tile T18NWL permitió cuantificar que la Vegetación constituye la cobertura dominante (527.369 ha, 43.7 %), seguida de Pastos (456.670 ha, 37.9 %), evidenciando la recuperación ecológica de la región en los casi 40 años transcurridos desde la tragedia de 1985. El depósito de lahar consolidado ocupa 132.863 ha (11.0 %), persistiendo como huella geomorfológica del evento volcánico.